

# Lezione 15 - Decomposizioni che hanno un join senza perdita

Prof.ssa Maria De Marsico  
demarsico@di.uniroma1.it



SAPIENZA  
UNIVERSITÀ DI ROMA

# Cosa significa join senza perdita



Quando uno schema di relazione viene di solito decomposto:

- **quando non è in 3NF**
- per motivi di efficienza degli accessi
  - più piccola è la taglia delle tuple maggiore è il numero che riusciamo a caricare in memoria nella stessa operazione di lettura
  - se le informazioni della tupla non vengono utilizzate dallo stesso tipo di operazioni nella base di dati meglio decomporre lo schema
  - Esempio: lo schema *Studiante* potrebbe essere decomposto separando le informazioni anagrafiche (CF, Nome, Cognome, DataNascita, LuogoNascita, ecc.) da quelle accademiche (Matricola, CorsoLaurea, AnnoCorso, ecc.)



- Abbiamo visto che quando uno schema viene decomposto, **non basta** che i sottoschemi siano in 3NF
- Rivediamo i due esempi (uno più «astratto», l'altro più «concreto»)

## Cosa vogliamo ottenere – La 3NF non basta



- Consideriamo lo schema  $R=ABC$  con l'insieme di dipendenze funzionali  $F=\{A \rightarrow B, C \rightarrow B\}$  (lo schema non è in 3NF per la presenza in  $F^+$  delle dipendenze parziali  $A \rightarrow B$  e  $C \rightarrow B$ , dato che la chiave è  $AC$ . Tale schema può essere decomposto in:
  - $R1=AB$  con  $\{A \rightarrow B\}$  e
  - $R2=BC$  con  $\{C \rightarrow B\}$ .
- Tale decomposizione **pur preservando tutte le dipendenze in  $F^+$**  non è soddisfacente.

# Cosa vogliamo ottenere – La 3NF non basta



- Consideriamo l'istanza **legale** di  $R$

|   |    |    |    |
|---|----|----|----|
| R | A  | B  | C  |
|   | a1 | b1 | c1 |
|   | a2 | b1 | c2 |

sono veri i due fatti  $(a1, b1, c1)$   
e  $(a2, b1, c2)$  e non altri

- In base alla decomposizione data, questa istanza si decompone in

|    |    |    |
|----|----|----|
| R1 | A  | B  |
|    | a1 | b1 |
|    | a2 | b1 |

|    |    |    |
|----|----|----|
| R2 | B  | C  |
|    | b1 | c1 |
|    | b1 | c2 |

- E dovrebbe essere possibile ricostruirla **esattamente** tramite join ... invece ...

# Cosa vogliamo ottenere – La 3NF non basta



- ... e invece se si effettua il join delle due istanze legali risultanti dalla decomposizione si ottiene

R

| A  | B  | C  |
|----|----|----|
| a1 | b1 | c1 |
| a2 | b1 | c2 |
| a1 | b1 | c2 |
| a2 | b1 | c1 |



tuple estranee alla realtà di interesse  
quindi  
perdita di informazione

- **Occorre garantire che il join delle istanze risultanti dalla decomposizione non riveli perdita di informazione**

## Cosa vogliamo ottenere – La 3NF non basta



Consideriamo ora lo schema

$R = (\text{Matricola}, \text{Provincia}, \text{Comune})$  con l'insieme di dipendenze funzionali

$F = \{ \text{Matricola} \rightarrow \text{Provincia}, \text{Comune} \rightarrow \text{Provincia} \}$  (lo schema non è in 3NF per la presenza in  $F^+$  delle dipendenze parziali  $\text{Matricola} \rightarrow \text{Provincia}$  e  $\text{Comune} \rightarrow \text{Provincia}$ , dato che la chiave è (Matricola, Comune) (Comune non è determinato da nessun altro attributo!)

Tale schema può essere decomposto in:

$R_1 = (\text{Matricola}, \text{Provincia})$  con  $\{ \text{Matricola} \rightarrow \text{Provincia} \}$  e

$R_2 = (\text{Provincia}, \text{Comune})$  con  $\{ \text{Comune} \rightarrow \text{Provincia} \}$ .

Tale schema **pur preservando tutte le dipendenze in  $F^+$**  non è soddisfacente.

# Cosa vogliamo ottenere – La 3NF non basta



Consideriamo l'i stanza **legale** di *R*

R

| Matricola | Provincia | Comune  |
|-----------|-----------|---------|
| 501       | Roma      | Tivoli  |
| 502       | Roma      | Mandela |

sono veri i due fatti *(501,Roma,Tivoli)* e *(501, Roma,Mandela)* e **non altri**

In base alla decomposizione data, questa istanza si scompone in

R1

| Matricola | Provincia |
|-----------|-----------|
| 501       | Roma      |
| 502       | Roma      |

R2

| Provincia | Comune  |
|-----------|---------|
| Roma      | Tivoli  |
| Roma      | Mandela |

E dovrebbe essere possibile ricostruirla **esattamente** tramite join ...  
invece ...



# Cosa vogliamo ottenere – La 3NF non basta



- ... e invece se si effettua il join delle due istanze legali risultanti dalla decomposizione si ottiene

R

| Matricola | Provincia | Comune  |
|-----------|-----------|---------|
| 501       | Roma      | Tivoli  |
| 502       | Roma      | Mandela |
| 501       | Roma      | Mandela |
| 502       | Roma      | Tivoli  |



tuple estranee alla realtà di interesse  
quindi  
perdita di informazione

# Cosa vogliamo ottenere – La 3NF non basta



In conclusione, quando si decompone uno schema occorre tenere presente il seguente requisito dello schema decomposto:

- deve permettere di **ricostruire mediante join naturale** ogni **istanza legale dello schema originario** (senza aggiunta di informazione estranea)

Se si decompone uno schema di relazione  $R$  si vuole che la **decomposizione**  $\{R_1, R_2, \dots, R_k\}$  ottenuta sia tale che **ogni istanza legale  $r$  di  $R$  sia ricostruibile** mediante **join naturale** ( $\bowtie$ ) da un istanza legale  $\{r_1, r_2, \dots, r_k\}$  dello schema decomposto  $\{R_1, R_2, \dots, R_k\}$ . Poiché per **ricostruire una tupla  $t$  di  $r$  è necessario che  $t[R_i] \in r_i, i=1, \dots, k$ , si deve avere  $r_i = \pi_{R_i}(r), i=1, \dots, k$ .**

**Definizione** Sia  $R$  uno schema di relazione. Una decomposizione  $\rho = \{R_1, R_2, \dots, R_k\}$  di  $R$  ha un join senza perdita se per ogni istanza legale  $r$  di  $R$  si ha  $r = \pi_{R_1}(r) \bowtie \pi_{R_2}(r) \bowtie \dots \bowtie \pi_{R_k}(r)$ .



- Anche in questo caso partiamo da una decomposizione data, e cerchiamo un modo per verificare che goda della proprietà desiderata.
- Anche in questo caso facciamo alcune premesse.

**Teorema** Sia  $R$  uno schema di relazione e  $\rho = \{R_1, R_2, \dots, R_k\}$  una decomposizione di  $R$ . Per ogni istanza legale  $r$  di  $R$ , indicato con  $m_\rho(r) = \pi_{R_1}(r) \bowtie \pi_{R_2}(r) \bowtie \dots \bowtie \pi_{R_k}(r)$ , si ha:

a)  $r \subseteq m_\rho(r)$

b)  $\pi_{R_i}(m_\rho(r)) = \pi_{R_i}(r)$

c)  $m_\rho(m_\rho(r)) = m_\rho(r)$ .

Dim.

Prova di a). Sia  $t$  una tupla di  $r$ . Per ogni  $i, i=1, \dots, k$ ,  $t[R_i] \in \pi_{R_i}(r)$  e quindi  $t \in m_\rho(r)$ .

- una **qualsiasi**, quindi vale per **ogni** tupla di  $r$
- Il **sottoinsieme** dei suoi valori su attributi di  $R_i$  sarà sicuramente in una tupla della proiezione  $\pi_{R_i}(r)$
- quindi **OGNI** sottoinsieme dei suoi valori **corrispondente** ad un elemento della decomposizione dello schema **comparirà in una tupla di un elemento** della decomposizione dell'istanza
- poiché anche la proiezione è un **insieme** di tuple al più i duplicati corrisponderanno ad una **unica tupla nella proiezione**
- **Quindi ogni tupla potrà essere ricostruita tramite il join naturale ...**
- **... anzi il join naturale potrebbe ottenere tuple che non erano in  $r$  ricomponendo pezzi di tuple diverse!**

Consideriamo la solita istanza **legale** di  $R=ABC$  con l'insieme di dipendenze funzionali  $F=\{A \rightarrow B, C \rightarrow B\}$  (no 3NF – dipendenze parziali)

| R | A  | B  | C  |
|---|----|----|----|
| r | a1 | b1 | c1 |
|   | a2 | b1 | c1 |
|   | a3 | b1 | c2 |

sono veri i fatti  $(a1, b1, c1)$  e  $(a2, b1, c1)$  e  $(a3, b1, c2)$  e **non altri**

Esempio: A= Matricola  
B= Provincia  
C= Comune

In base ad una delle possibili decomposizioni dello schema , questa istanza si decompone in

| R1            | A  | B  |
|---------------|----|----|
| $\pi_{R1}(r)$ | a1 | b1 |
|               | a2 | b1 |
|               | a3 | b1 |

| R2            | B  | C  |
|---------------|----|----|
| $\pi_{R2}(r)$ | b1 | c1 |
|               | b1 | c2 |

La prima è ottenuta proiettando l'istanza originale su AB  
La seconda è ottenuta proiettando l'istanza originale su BC (notare l'eliminazione del duplicato)  
Forse questa eliminazione ci farà perdere tuple originali? **NO**

Dovrebbe essere possibile ricostruire l'istanza di partenza **esattamente** tramite join ... invece ...

# Cosa vogliamo ottenere – La 3NF non basta



- ... e invece se si effettua il join delle due istanze legali risultanti dalla decomposizione si ottiene

| R | A  | B  | C  |
|---|----|----|----|
|   | a1 | b1 | c1 |
|   | a1 | b1 | c2 |
|   | a2 | b1 | c1 |
|   | a2 | b1 | c2 |
|   | a3 | b1 | c1 |
|   | a3 | b1 | c2 |

$$m_{\rho}(r) = \pi_{R1}(r) \bowtie \pi_{R2}(r)$$

tuple estranee alla realtà di interesse  
quindi  
perdita di informazione (ma non di  
tuple!)

$$r \subset m_{\rho}(r)$$

- Occorre garantire che il join delle istanze risultanti dalla decomposizione non riveli perdita di informazione

## Insiemi di tuple

Procediamo provando la **doppia inclusione**

Prova di b).  $\pi_{R_i}(m_{\rho}(r)) = \pi_{R_i}(r)$

Per **a)** si ha  $r \subseteq m_{\rho}(r)$  e, quindi,  $\pi_{R_i}(r) \subseteq \pi_{R_i}(m_{\rho}(r))$ .

E' sufficiente, pertanto, mostrare che  $\pi_{R_i}(r) \supseteq \pi_{R_i}(m_{\rho}(r))$ .

Banalmente, per ogni tupla  $t \in m_{\rho}(r)$  e per ogni  $i$ ,  $i=1, \dots, k$ , deve esistere una tupla  $t' \in r$  tale  $t[R_i] = t'[R_i]$ . Se tale tupla non esistesse, non troveremmo i valori di  $t$  su  $R_i$  ( $t[R_i]$ ) nella proiezione  $\pi_{R_i}(r)$  e di conseguenza non li avremmo nel join naturale



# Digressione



| R | A  | B  | C  |
|---|----|----|----|
| r | a1 | b1 | c1 |
|   | a2 | b1 | c1 |
|   | a3 | b1 | c2 |

| R1            | A  | B  |
|---------------|----|----|
| $\pi_{R1}(r)$ | a1 | b1 |
|               | a2 | b1 |
|               | a3 | b1 |

| R2            | B  | C  |
|---------------|----|----|
| $\pi_{R2}(r)$ | b1 | c1 |
|               | b1 | c2 |

$$m_{\rho}(r) = \pi_{R1}(r) \bowtie \pi_{R2}(r)$$


| R | A  | B  |
|---|----|----|
|   | a1 | b1 |
|   | a1 | b1 |
|   | a2 | b1 |
|   | a2 | b1 |
|   | a3 | b1 |
|   | a3 | b1 |

$$\pi_{R1}(m_{\rho}(r))$$

| R | A  | B  | C  |
|---|----|----|----|
|   | a1 | b1 | c1 |
|   | a1 | b1 | c2 |
|   | a2 | b1 | c1 |
|   | a2 | b1 | c2 |
|   | a3 | b1 | c1 |
|   | a3 | b1 | c2 |

$$\pi_{R2}(m_{\rho}(r))$$

| R | B  | C  |
|---|----|----|
|   | b1 | c1 |
|   | b1 | c2 |
|   | b1 | c1 |
|   | b1 | c2 |
|   | b1 | c1 |
|   | b1 | c2 |

 duplicati  
= vengono  
eliminati  
dalla  
proiezione

Prova di c).  $m_{\rho}(m_{\rho}(r))=m_{\rho}(r)$ .

Per b) si ha  $\pi_{Ri}(m_{\rho}(r))=\pi_{Ri}(r)$ .

Pertanto , applicando la definizione dell'operatore  $m_{\rho}$  (join delle proiezioni) avremo

$$\begin{aligned} m_{\rho}(m_{\rho}(r)) &= \pi_{R1}(m_{\rho}(r)) \bowtie \pi_{R2}(m_{\rho}(r)) \bowtie \dots \bowtie \pi_{Rk}(m_{\rho}(r)) = \\ &\pi_{R1}(r) \bowtie \pi_{R2}(r) \bowtie \dots \bowtie \pi_{Rk}(r) = m_{\rho}(r). \end{aligned}$$

| A         | B         | C         |
|-----------|-----------|-----------|
| a1        | b1        | c1        |
| <b>a1</b> | <b>b1</b> | <b>c2</b> |
| a2        | b1        | c1        |
| <b>a2</b> | <b>b1</b> | <b>c2</b> |
| <b>a3</b> | <b>b1</b> | <b>c1</b> |
| a3        | b1        | c2        |

| A         | B         | C         |
|-----------|-----------|-----------|
| a1        | b1        | c1        |
| <b>a1</b> | <b>b1</b> | <b>c2</b> |
| a2        | b1        | c1        |
| <b>a2</b> | <b>b1</b> | <b>c2</b> |
| <b>a3</b> | <b>b1</b> | <b>c1</b> |
| a3        | b1        | c2        |



| R | A  | B  |
|---|----|----|
|   | a1 | b1 |
|   | a2 | b1 |
|   | a3 | b1 |

| R | B         | C         |
|---|-----------|-----------|
|   | b1        | c1        |
|   | <b>b1</b> | <b>c2</b> |

$$m_{\rho}(m_{\rho}(r)) = \pi_{R1}(m_{\rho}(r)) \triangleright \triangleleft \pi_{R2}(m_{\rho}(r))$$

- Abbiamo uno schema di relazione  $R$ , un insieme di dipendenze funzionali  $F$  e una decomposizione  $\rho$ .
- Come facciamo a verificare che la decomposizione data ha un join senza perdita?
- L'algoritmo che mostriamo permette di effettuare la verifica in tempo polinomiale.
- **F ci serve perché ... ci serviremo di nuovo di una particolare istanza legale di  $R$**

# Algoritmo di verifica



SAPIENZA  
UNIVERSITÀ DI ROMA  
DIPARTIMENTO DI INFORMATICA

## Algoritmo – verifica che una decomposizione abbia del join senza perdita

**Input** uno schema di relazione  $R$ , un insieme  $F$  di dipendenze funzionali su  $R$ , una decomposizione  $\rho = \{R_1, R_2, \dots, R_k\}$  di  $R$ ;

**Output** decide se  $\rho$  ha un join senza perdita;

**begin**

Costruisci una tabella  $r$  nel modo seguente:

$r$  ha  $|R|$  colonne e  $|\rho|$  righe

all'incrocio dell' $i$ -esima riga e della  $j$ -esima colonna metti

il simbolo  $a_j$  se l'attributo  $A_j \in R_i$

il simbolo  $b_{ij}$  altrimenti

**repeat**

**for every**  $X \rightarrow Y \in F$

**do if** ci sono due tuple  $t_1$  e  $t_2$  in  $r$  tali che  $t_1[X] = t_2[X]$  e  $t_1[Y] \neq t_2[Y]$

**then for every attribute**  $A_j$  in  $Y$  **do if**  $t_1[A_j] = 'a_j'$  **then**  $t_2[A_j] := t_1[A_j]$

**else**  $t_1[A_j] := t_2[A_j]$

**until**  $r$  ha una riga con tutte 'a' **or**  $r$  non è cambiato;

**if**  $r$  ha una riga con tutte 'a' **then**  $\rho$  ha un join senza perdita

**else**  $\rho$  non ha un join senza perdita

**end**

una colonna per ogni attributo di  $R$  e una riga per ogni elemento della decomposizione (sottoschema)

l'attributo  $A_j$  fa parte del sottoschema  $R_i$

Indice  $i$  = elemento della decomposizione = riga  
Indice  $j$  = attributo = colonna

gestiamo correttamente  
anche il caso in cui  $t_2[A_j] = 'a_j'$

**anche in questo caso  
l'algoritmo termina sempre!  
occorre poi verificare se in  $r$   
c'è la tupla che cerchiamo**



- Possiamo considerare gli  $a_j$  come valori particolari appartenenti al dominio dell'attributo  $A_j$
- Possiamo considerare i  $b_{ij}$  come valori particolari appartenenti al dominio dell'attributo  $A_j$
- Possiamo considerare **tutti i valori  $a_j$**  uguali tra di loro
- Il valore  $b_{ij}$  è diverso da  $a_j$  e da un altro valore  $b_{kj}$  anche se appartengono tutti allo stesso dominio (quello dell'attributo  $A_j$  )
- Come **conseguenza**, la nostra  $r$  iniziale è una particolare **istanza** dello schema  $R$



- Per i nostri scopi, trasformiamo questa istanza iniziale in una **istanza legale**
- Per fare questo, dobbiamo fare in modo che **tutte** le dipendenze in  $F$  siano **soddisfatte**
- Allora, ogni volta che troviamo due tuple uguali sugli attributi a sinistra, facciamo in modo che siano uguali anche su quelli a destra (attributo per attributo!)
- Nel fare questo, diamo la precedenza alle  $a$  (non diventano MAI  $b$ )

- Se due tuple sono **uguali sulla parte sinistra** ma sono **diverse in un attributo della parte a destra** della dipendenza, e **una delle due** ha una ***a*** come valore di quell'attributo, facciamo **diventare *a*** anche il valore dell'attributo nell'altra tupla
- Se due tuple sono **uguali sulla parte sinistra** ma sono **diverse in un attributo della parte a destra** della dipendenza, e **nessuna delle due** ha una ***a*** come valore di quell'attributo, facciamo diventare uguali le due ***b*** (ad esempio, se abbiamo  $b_{ij}$  e  $b_{kj}$  facciamo diventare entrambi i valori  $b_{ij}$  oppure  $b_{kj}$  )
- In pratica due valori saranno uguali **se sono entrambi *a*** oppure **se hanno una *b* con lo stesso pedice**
- L'algoritmo di ferma quando **TUTTE** le coppie di tuple soddisferanno la condizione che **se** gli attributi delle parti sinistre delle dipendenze sono uguali, **lo sono anche** gli attributi delle parti destre
- Ma questo significa che **alla fine *r* è stata trasformata in un'istanza legale di R**



- **Teorema** Sia  $R$  uno schema di relazione,  $F$  un insieme di dipendenze funzionali su  $R$  e  $\rho = \{R_1, R_2, \dots, R_k\}$  una decomposizione di  $R$ . L'Algoritmo di verifica decide correttamente se  $\rho$  ha un join senza perdita.
- **Dim.** Occorre dimostrare che:
- $\rho$  ha un join senza perdita ( $m_\rho(r) = r$  per ogni  $r$  legale)
  - **se e solo se**
- **quando l'algoritmo termina la tabella  $r$  ha una tupla con tutte 'a'.**

- **Parte solo se.**
  - Supponiamo **per assurdo** che  $\rho$  abbia un join senza perdita ( $m_\rho(r) = r$ ) e che quando l'algoritmo termina la tabella  $r$  **non abbia** una tupla con tutte 'a'. La tabella  $r$  può essere interpretata come **un'istanza legale di  $R$**  (basta sostituire ai simboli 'a' e 'b' valori presi dai domini dei corrispondenti attributi in modo tale che ad uno stesso simbolo venga sostituito lo stesso valore) in quanto l'algoritmo termina quando **non ci sono più violazioni delle dipendenze in  $F$** . Poiché **nessun simbolo 'a' che compare nella tabella costruita inizialmente viene mai modificato** dall'algoritmo, per ogni  $i, i=1, \dots, k$ ,  $\pi_{R_i}(r)$  contiene (fin dall'inizio!) una tupla con tutte 'a' (quella ottenuta **proiettando l'istanza  $r$  sugli attributi di  $R_i$**  e precisamente nella riga corrispondente **al sottoschema  $R_i$** ) pertanto  $m_\rho(r)$  **contiene sicuramente una tupla con tutte 'a' e, quindi,  $m_\rho(r) \neq r$  (contraddizione).**



- **Parte se**

- Per uno sketch della prova della parte “se” consultare il testo J. D. Ullman, “Principles of database and knowledge-base systems”, vol. I, Computer Science Press, 1988.
- Una scansione delle pagine rilevanti verrà fornita insieme alle dispense del corso.

- **Corollario** Sia  $R$  uno schema di relazione,  $F$  un insieme di dipendenze funzionali su  $R$  e  $\rho = \{R_1, R_2\}$  una decomposizione di  $R$ .
  - Se  $R_1 \cap R_2 \rightarrow R_1 - R_2$  o  $R_1 \cap R_2 \rightarrow R_2 - R_1$  allora  $\rho$  ha un join senza perdita.

Osservazione banale:  $R_1 = (R_1 - R_2) \cup (R_1 \cap R_2)$  e  $R_2 = (R_2 - R_1) \cup (R_1 \cap R_2)$

|       | $R_1 - R_2$                 | $R_1 \cap R_2$        | $R_2 - R_1$                 |
|-------|-----------------------------|-----------------------|-----------------------------|
| $R_1$ | <u><math>a</math></u>       | <u><math>a</math></u> | <u><math>b_{2-1}</math></u> |
| $R_2$ | <u><math>b_{1-2}</math></u> | <u><math>a</math></u> | <u><math>a</math></u>       |

Possiamo riordinare gli attributi in modo da avere un quadro più immediato della distribuzione dei valori nell'istanza di  $R$

$a$ ,  $b_{2-1}$ , e  $b_{1-2}$  sono vettori di valori del tipo  $a_j$  o  $b_{ij}$

In base a  $R_1 \cap R_2 \rightarrow R_1 - R_2$  o  $R_1 \cap R_2 \rightarrow R_2 - R_1$  applicando l'algoritmo una delle due tuple (rispettivamente la seconda o la prima) diventerà di tutte  $a$

Non è necessario che  $R_1 \cap R_2 \rightarrow R_1 - R_2$  o  $R_1 \cap R_2 \rightarrow R_2 - R_1$  siano in  $F$ , è sufficiente che siano in  $F^+$  ...